

Grado en

Business Data Analytics

Informe final

Reto: 05 Laboral Kutxa

Curso: 2º 2023-2024

Equipo: Verde oscuro

URL del repositorio en GitHub: [enlace al repositorio](#)

Ruta de la carpeta de Google Drive que contiene el proyecto:

VERDEOSCURO\R5_Entrega_VERDEOSCURO

Autores:

- Ane Aizpuru Ruiloba
- June Dorronsoro Elicegui
- Lian Etxebarria Rivero
- Julen Fernández Fernández
- June Marquínez Abad
- Guillermo Rubio Ramírez

23-24_2_R5_verdeoscuro

Índice

1. Introducción	5
2. Identificar la problemática	6
2.1 Sobre el cliente	6
2.2 Sobre la problemática	6
2.3 Objetivos	6
3. Recoger y almacenar los datos	7
3.1 Fuentes de datos utilizadas	7
3.2 Procesamiento de los datos	7
4. Analizar y modelar los datos	9
4.1 Análisis descriptivos	9
4.2 Modelar los datos y Visualizar los resultados obtenidos	11
4.3 Conclusiones	17
5. Transformar los negocios	20
6. Implicaciones legales y éticas	22
Bibliografía	24
Apéndice I: Interpretaciones matemáticas	26
Apéndice II: InfluxDB	28
Glosario de terminología	30
Glosario de siglas	31

Índice de figuras

Figura 1: Serie temporal del PIB	9
Figura 2: Serie temporal del IPC	9
Figura 3: ACF del PIB	10
Figura 4: ACF del IPC	10
Figura 5: PACF del PIB	11
Figura 6: PACF del IPC	11
Figura 7: Comparación serie del PIB en condiciones COVID y en condiciones normales	12
Figura 8: Serie temporal del PIB transformada	12
Figura 9: Gráficos de los residuos del modelo $ARIMA(0,1,0)(0,1,1)[4]$	12
Figura 10: Gráficos de los residuos del modelo $ARIMA(0,1,1)(3,1,3)[4]$	13
Figura 11: Gráfico de la predicción del PIB para el cuarto trimestre de 2022	14
Figura 12: Serie temporal del IPC transformada	15
Figura 13: Gráficos de los residuos del modelo $ARIMA(4,0,0)(0,1,1)[12]$	15
Figura 14: Gráficos de los residuos del modelo $ARIMA(6,0,6)$	16
Figura 15: Gráfico de las predicciones del IPC para el último trimestre de 2022	17

Índice de tablas

Tabla 1: Métricas del modelo ARIMA(0,1,0)(0,1,1)[4]	13
Tabla 2: Métricas del modelo ARIMA(0,1,1)(3,1,3)[4]	13
Tabla 3: Predicción del PIB para el tercer trimestre de 2022 con el modelo ARIMA(0,1,1)(3,1,3)[4]	14
Tabla 4: Métricas del modelo ARIMA(6,0,6)	16
Tabla 5: Métricas del modelo ARIMA(6,0,6)	16
Tabla 6: Predicción del IPC para el tercer trimestre de 2022 con el modelo ARIMA(6,0,6)	17
Tabla 7: Comparativa entre valor real, nuestra predicción y la predicción de ISTAT para el PIB	19
Tabla 8: Comparativa entre valor real, nuestra predicción y la predicción de ISTAT para el IPC	19

1. Introducción

Históricamente, tanto la tesorería como el mercado de capitales de los bancos han sido gestionados y asesorados por personas especialistas en la materia. Sin embargo, a lo largo de los últimos años, el sector financiero, al igual que muchos otros, ha comenzado a apoyarse en el **criterio de la inteligencia artificial** con la intención de reducir el riesgo y aumentar los beneficios, consiguiendo así ventaja competitiva respecto a los competidores..

Esta nueva práctica consiste en crear modelos que se alimenten de datos y acontecimientos anteriores y predigan situaciones futuras **sin dejarse influenciar por las emociones**, algo a lo que son vulnerables las personas humanas y que a menudo juega en su contra.

Si bien es cierto que el juicio de un modelo con pocos datos es poco fiable, a medida que este va recopilando información se va volviendo cada vez más preciso, ya que, como se ha mencionado anteriormente, este **aprende de sucesos pasados**. A través de estos modelos se puede llegar a **conclusiones únicas y muy interesantes** que difícilmente se lograrían mediante el análisis convencional hecho por una persona.

Este informe contiene una explicación detallada sobre los **procedimientos y análisis** realizados para dar **respuesta a la problemática** planteada, así como la redacción de las **conclusiones** a las que se ha llegado y las **sugerencias** que se proponen a los clientes de Laboral Kutxa.

En cuanto a las **limitaciones** que han ido surgiendo a lo largo del camino, se podría destacar la dificultad a la hora de encontrar datos reales tanto del PIB como del IPC, pues los datos de los que se dispone proceden de una página que requiere de una suscripción de pago. Finalmente, hubo que recurrir a otras fuentes, donde la información era similar pero variaba un poco respecto a la que se disponía.

2. Identificar la problemática

2.1 Sobre el cliente

Este informe se dirige a **Laboral Kutxa**, una de las entidades financieras más solventes de España y la cual tiene gran presencia en el País Vasco. Actualmente, Laboral Kutxa cuenta con alrededor de 1.3 millones de clientes, concentrados principalmente en la Comunidad Autónoma Vasca.

Laboral Kutxa fue fundada en el año **1959** por José María Arizmendiarrreta, con el objetivo de promover el ahorro popular y canalizar los recursos económicos de las empresas que habían empezado a florecer en la comarca del Alto Deva. Laboral Kutxa es una de las empresas que conforman la **Cooperativa Mondragón**, siendo una de las más importantes.

Durante las décadas de los 70 y 80, Laboral Kutxa se sumerge en una etapa de expansión y consolidación, las cuales le llevaron a ser una de las bancas con más peso en el País Vasco. Más tarde, en la década de los 90 concretamente, se empiezan a ofrecer servicios nuevos, como la Bolsa Online. Asimismo, se desarrollan nuevos modelos de negocio, como Gaztempresa, con el fin de impulsar iniciativas de jóvenes emprendedores.

Una de las características que diferencia a Laboral Kutxa de las demás entidades financieras es que, al ser una cooperativa, **las decisiones que se toman están en manos de los socios y de las demás empresas que forman la Cooperativa Mondragón.**

2.2 Sobre la problemática

Una vez adquiridos los conocimientos económicos necesarios y entendiendo los índices proporcionados se ha pedido **analizar las trayectorias del PIB y el IPC** a lo largo de los años y **predecir su valor para el último trimestre de 2022**; para ello, es fundamental tener en cuenta los diferentes índices que pueden afectar sus respectivos recorridos del PIB.

2.3 Objetivos

La finalidad del Reto 5 es crear modelos para poder **predecir el IPC y el PIB** para el último trimestre del año 2022, en este caso, de Italia. Basándose en las predicciones del modelo se deben crear diferentes recomendaciones para los clientes interesados en expandirse al mercado.

Tras realizar el objetivo, se debe **comparar la predicción** conseguida con las predicciones que se realizaron por alguna autoridad oficial. Además, se deben contrastar los resultados obtenidos desde ambas predicciones con los datos reales para poder así evaluar tanto nuestro modelo como sus respectivas predicciones.

3. Recoger y almacenar los datos

3.1 Fuentes de datos utilizadas

Los datos utilizados para realizar este reto son los proporcionados por **Laboral Kutxa**. Estos datos se dividen en dos ficheros, uno de tipo `.csv` y el otro de tipo `.xlsx`, pero ambos provenientes de la página web *theglobaleconomy.com*. En cuanto al primer fichero de nombre “`pib_ipc_paises2.csv`”, los datos son los **índices de PIB e IPC** de distintos países; el índice del IPC se muestra por mes y el del PIB por trimestres. Este fichero consta de 7 columnas, siendo dos de ellas los índices mencionados anteriormente, otras dos el tiempo en meses y años con un horizonte temporal entre 1966 y 2022, y el resto información sobre el país (código del país, código de continente, etc.).

El segundo fichero, *exogenas_paises_punto2.xlsx*, trata sobre **variables exógenas** de diferentes países. En este excel se muestran 8 columnas, la mayoría compartidas con el fichero anterior. Las únicas variables diferentes son las variables económicas, en este caso la masa monetaria dada en billones, la tasa de desempleo dada en porcentajes y el índice de la bolsa.

3.2 Procesamiento de los datos

El procesamiento de datos trata principalmente de **transformar y manipular la información para conseguir una mayor utilidad y relevancia de la misma**. En este contexto, el equipo Verde Oscuro ha llevado a cabo este proceso de manera rigurosa y detallada siguiendo los pasos que se explican a continuación.

En primer lugar, se han realizado tanto una **limpieza** como una **exploración** con el objetivo de comprender su contenido y estructura e identificar y corregir datos incorrectos, incompletos o irrelevantes. Para ello, el primer paso ha sido **cargar los archivos** que albergaban los datos. Como se ha comentado anteriormente, estos archivos estaban en formatos diferentes; por un lado, el archivo “`.csv`” se importó mediante la función `read.csv()`, y por otro lado, el archivo “`.xlsx`” mediante la función `read.xlsx2()`.

Con la información necesaria ya importada, se ha decidido primero separar la tabla con la información sobre el IPC y el PIB en dos, pues el primero contenía valores mensuales y el segundo trimestrales. Después, se realizó un análisis genérico de los archivos mediante la **previsualización de los datos** utilizando funciones como `dim()`, `str()`, `head()` y `colnames()`. Además, se han obtenido los **estadísticos descriptivos** ya que todos los datos que se disponían eran de tipo numérico. Esto se ha realizado con la función `summary()`, que se ha aplicado en todas las tablas. Esta función también ha permitido conocer los valores ausentes que había en cada columna, pudiendo observar que, aún siendo pocos, estos se concentraban en los primeros y últimos años. Con esto en mente, se ha optado por omitir las filas que contenían missings y quedarse solo con las **filas completas**. Igualmente, se les ha aplicado la función `duplicate()` a las tres tablas para identificar las posibles instancias duplicadas y evitar trabajar ellas más adelante; sin embargo, no ha sido necesario modificar nada en los datos pues todos los valores eran únicos.

Por último, ya con los datos limpios y listos para manipular, se ha decidido separar la tabla con la información sobre el IPC y el PIB en dos para que resulten más fáciles de analizar,

pues el primero contenía valores mensuales y el segundo trimestrales. Así, se han hecho **histogramas** con la ayuda de la función *hist()* para ambos índices, así como para el resto de las variables, “money.supply.million.currency.units”, “unemployment.rate.percent” y “stock.market.index”, para ver su distribución.

4. Analizar y modelar los datos

4.1 Análisis descriptivos

Los datos analizados se han transformado en series temporales a través de *RStudio*. Después, con la intención de facilitar al cliente su visualización y comprensión, se ha optado por graficarlas mediante la función *plot()*.

En cuanto a la **serie temporal del PIB**, en el gráfico número 1 se puede observar tanto una clara **tendencia ascendente** a lo largo de los años como una **estacionalidad**, pues los datos siguen un patrón simétrico desde el inicio. En contraposición, se pueden ver dos **momentos cíclicos**; el primero de ellos en el 2008 como consecuencia de la crisis, la cual mantuvo la serie constante durante un tiempo, y el segundo en 2020, entendiéndose como las consecuencias del COVID-19 a pesar de volver a recuperar la tendencia a partir de 2021.




Figura 1: Serie temporal del PIB

En el gráfico número 2 se puede observar la **serie temporal del IPC**, donde, al igual que en el gráfico del PIB, se aprecia una **tendencia ascendente** evidente, aunque **no** un curso del todo **estacional**, pues los movimientos no son completamente recurrentes. Los sucesos de los años 2008 y 2020 ya mencionados también se hacen notar, aunque en el caso del PIB la tendencia empieza a volver a su normalidad tras dichas crisis mientras que, en este otro caso, el aumento del valor del índice es despiadado.




Figura 2: Serie temporal del IPC

Los siguientes **gráficos de autocorrelación** muestran una tendencia descendente en ambas series temporales, siendo la bajada del PIB la más pronunciada. Asimismo, el primero de los gráficos también evidencia una estacionalidad. El hecho de que la autocorrelación del IPC se reduzca de manera menos agresiva y seguida indica una mayor autocorrelación de los datos, pues son más similares entre sí.




Figura 3: ACF del PIB




Figura 4: ACF del IPC

Por otro lado, en los próximos gráficos se refleja la **autocorrelación parcial**, indicando la relación entre los datos sin tener en cuenta los datos intermedios y mostrando cada cuantos retardos hay más similitud entre los datos. Para saber cuales son los retardos con más correlación hay que tener en cuenta las barras que salen del ruido blanco. **Respecto al PIB**, se puede ver que **los datos se parecen cada dos y cuatro retardos positivamente y cada cinco negativamente. Los datos del IPC**, en cambio, no salen del ruido blanco, por lo que **no tienen parecido** a sus anteriores.




Figura 5: PACF del PIB




Figura 6: PACF del IPC

4.2 Modelar los datos y Visualizar los resultados obtenidos

Uno de los objetivos de este reto propuesto por Laboral Kutxa trata de realizar las predicciones de PIB e IPC para el último trimestre de 2022, lo cual se ha hecho mediante **modelos de minería de datos**. El proceso ha sido el siguiente:

Primero, se han transformado los datos mediante el comando `ts()` para convertirlos en series temporales. Además, para poder tener una mejor entendimiento de estos se han graficado las series con `ts.plot()`, los gráficos de autocorrelación con `ggAcf()` y los de autocorrelación parcial con `ggPacf()`. De esta manera, se han podido identificar de manera clara las tendencias y estacionalidades que los datos presentan.

- **Modelización del PIB:**

En cuanto al PIB, dado que los datos de los años de la COVID-19 (2020 y 2021) eran muy atípicos, se ha optado por no usarlos. En su lugar, se han predecido esos dos años con los datos hasta el 2019, para luego usarlos en las predicciones finales (el último trimestre de 2022). Las primeras predicciones se han hecho utilizando un modelo $ARIMA(1,1,2)(0,1,1)$ y se ha seguido el mismo proceso que el de las predicciones finales que se explica a continuación. Una vez obtenidos los valores predichos para esos dos años, se han sustituido los datos

originales con las predicciones. Posteriormente, se ha hecho la **partición de los datos** en train y test, contando con los valores recogidos hasta el 2021 para el train y con los de los dos primeros trimestres de 2022 para el test.

Con esto, se han realizado las **transformaciones** necesarias para que la serie temporal sea estacionaria. Primero, se ha **estabilizado la varianza** mediante la función `BoxCox()`. El parámetro “lambda” necesario para la función anterior se ha escogido a partir de la función `BoxCox.lambda()`.

A pesar de tener una serie temporal con tendencia y estacionalidad, no se ha procedido a eliminarlas, ya que, tras varias comprobaciones, se ha llegado a la conclusión de que la mejor solución era utilizar un modelo SARIMA, el cual no requiere de su eliminación. En el gráfico 8 se puede observar la serie temporal del PIB con los datos de los años del COVID-19 sustituidos y la varianza estabilizada. En el gráfico 7 se puede apreciar cuál es el cambio en la serie temporal.




Figura 7: Comparación serie del PIB en condiciones COVID y en condiciones normales




Figura 8: Serie temporal del PIB transformada

En el gráfico número 9 se pueden observar los resultados obtenidos del modelo que ha realizado la función `auto.arima()`. En este caso, ha escogido un modelo **ARIMA(0,1,0)(0,1,1)**, el cual no ha dado un resultado demasiado bueno pues los residuos **no presentan ruido blanco**, como se puede observar en la parte inferior izquierda del gráfico.




Figura 9: Gráficos de los residuos del modelo $ARIMA(0,1,0)(0,1,1)[4]$

Para **calcular la precisión** de los diferentes modelos, se han predecido los dos siguientes trimestres. Sin embargo, anteriormente se habían realizado transformaciones para estabilizar la varianza. Consecuentemente, para calcular el accuracy de cada modelo, lo primero que se ha hecho es la **reversión** de estas **transformaciones** utilizando la función *InvBoxCox()*. Las métricas de error obtenidas para el primer modelo han sido las siguientes:

	ME	RMSE	MAE
Accuracy	1.567497	4.755612	4.489854

Tabla 1: Métricas del modelo $ARIMA(0,1,0)(0,1,1)[4]$

En el gráfico número 10 se pueden observar los resultados obtenidos del modelo **$ARIMA(0,1,1)(3,1,3)$** . Tal y como se puede visualizar, se está ante un modelo bastante adecuado ya que, en este caso, los residuos **sí presentan ruido blanco**.




Figura 10: Gráficos de los residuos del modelo $ARIMA(0,1,1)(3,1,3)[4]$

Las métricas de error de este segundo modelo se pueden ver en la siguiente tabla:

	ME	RMSE	MAE
Accuracy	-0.8228654	4.127573	4.044719

Tabla 2: Métricas del modelo $ARIMA(0,1,1)(3,1,3)[4]$

Finalmente, el **modelo escogido** para realizar las predicciones ha sido el segundo, el modelo **$ARIMA(0,1,1)(3,1,3)[4]$** . La razón por la que se ha escogido ha sido su precisión, que supera a la del modelo realizado por *auto.arima()* y el hecho de que sus residuos son ruido blanco. Así, la predicción del PIB obtenida para el último trimestre del 2022 se puede observar en la siguiente tabla así como en la figura 10.

	Cuarto trimestre del 2022
Predicción	495.179

Tabla 3: Predicción del PIB para el cuarto trimestre de 2022 con el modelo $ARIMA(0,1,1)(3,1,3)[4]$




Figura 11: Gráfico de la predicción del PIB para el cuarto trimestre de 2022

- **Modelización del IPC:**

En lo que al IPC respecta, para la partición de los datos se ha decidido utilizar el método de **validación cruzada** con cuatro iteraciones, por lo que se han tenido que partir los datos en cuatro sets de train y cuatro sets de test. Estas particiones se han hecho respetando el orden cronológico de los datos, ya que los datos de los que se dispone son series temporales.

Una vez terminada la partición, se ha procedido a realizar las **transformaciones** necesarias para que la serie temporal sea estacionaria. Para ello, lo primero ha sido **estabilizar la varianza** mediante la función *BoxCox()*. El parámetro lambda necesario para la función anterior se ha escogido, de nuevo, a partir de la función *BoxCox.lambda()*.

Después, al tener una serie temporal con tendencia y estacionalidad, se han tenido que realizar aún más transformaciones. Primero, con la intención de visualizar cómo quedaría la serie libre de tendencia y de estacionalidad, se ha empleado la función *decompose()*.

Más tarde, con el fin de por fin quitarle la **tendencia** a la serie temporal, se ha hecho la primera diferencia mediante la función *diff()*. Por otro lado, en el caso de la **estacionalidad**, la cual es de frecuencia semestral, se ha hecho la sexta diferencia.

En el gráfico número 12, se puede observar la serie sin tendencia ni estacionalidad, en la que se puede apreciar una caída en el año 2020 como consecuencia de la pandemia del COVID-19. Sin embargo, como en este caso la bajada no es tan notable como en el caso del PIB, se ha optado por mantener los datos originales.




Figura 12: Serie temporal del IPC transformada

Con la serie temporal ya transformada, se ha procedido a realizar los modelos. Al igual que se ha hecho con el PIB, se han realizado dos modelos, uno realizado con la función *auto.arima()* y otro en la que se han elegido los parámetros en función del criterio de evaluación AIC, escogiendo entre una lista de modelos el que menor valor de AIC tenía.

En el gráfico número 13 se pueden observar diferentes gráficos realizados con los residuos del modelo hecho por *auto.arima()*. En esta ocasión, la función *auto.arima()* ha escogido un modelo **ARIMA(4,0,0)(0,1,1)[12]**. Una de las características que tienen que tener los residuos para considerar el modelo como bueno es el **ruido blanco**, lo que no sucede aquí tal y como muestra el gráfico situado en la parte inferior izquierda de la figura. Es por esta razón que este modelo no se puede considerar como suficiente.




Figura 13: Gráficos de los residuos del modelo $ARIMA(4,0,0)(0,1,1)[12]$

En la tabla número 4 se pueden observar los valores de ME, RMSE, MAE, los cuales son otra forma de valorar la precisión del modelo. **Según el RMSE, el modelo es altamente preciso** pues los valores oscilan entre 0,64 y 1,74. Cabe destacar que, para calcular la precisión del modelo, a diferencia del modelo del PIB, se han predicho cuatros meses para cada set de train. La razón de este cambio es que en este caso se disponía de una serie temporal mensual en vez de trimestral.

	ME	RMSE	MAE
Accuracy para train_1	0.4372905	0.6434091	0.4465385
Accuracy para train_2	0.8079521	0.9509657	0.8079521
Accuracy para train_3	1.696316	1.740226	1.696316
Accuracy para train_4	0.706557	0.706557	0.6120711

Tabla 4: Métricas del modelo $ARIMA(4,0,0)(0,1,1)[12]$

Los gráficos que se pueden observar en el gráfico número 14 pertenecen a los residuos del modelo **$ARIMA(6,0,6)$** . Para elegir los parámetros p y q se han ido probando diferentes combinaciones, de las cuales se ha elegido el modelo con menor AIC. Este modelo, como bien se puede comprobar en el gráfico de la parte inferior izquierda, es bastante adecuado, ya que los residuos **presentan ruido blanco**.




Figura 14: Gráficos de los residuos del modelo ARIMA(6,0,6)

En la siguiente tabla se visualizan las **métricas de calidad** del segundo modelo, donde el RMSE asegura que se trata de un modelo **bastante preciso**, dado que los valores varían en un rango estrecho, oscilando entre 0.64 y 1.79.

	ME	RMSE	MAE
Accuracy para train_1	0.4372905	0.6434091	0.4465385
Accuracy para train_2	0.9366659	1.040742	0.9366659
Accuracy para train_3	1.729645	1.789409	1.729645
Accuracy para train_4	1.332586	1.4054	1.332586

Tabla 5: Métricas del modelo ARIMA(6,0,6)

Finalmente, en lo que al **IPC** se refiere, el **modelo seleccionado** para realizar las predicciones finales es el modelo **ARIMA(6,0,6)**. Para la elección se han tenido en cuenta las métricas de error ligeramente más favorables que en el otro modelo, y los residuos, que sí se comportan como ruido blanco. Las predicciones que se han conseguido para los meses que conforman el último trimestre del año 2022 en relación al Índice de Precios de Consumo se recogen y se grafican en la siguiente tabla y el siguiente gráfico.

	Octubre 2022	Noviembre 2022	Diciembre 2022
Predicciones	114.8475	115.5304	116.3154

Tabla 6: Predicciones del IPC para el último trimestre de 2022 con el modelo ARIMA(6,0,6)




Figura 15: Gráfico de las predicciones del IPC para el último trimestre de 2022

4.3 Conclusiones

Tras haber finalizado los análisis descriptivos así como el proceso de modelización de los datos, en este apartado se desarrollarán las conclusiones a las que se ha llegado.

Tanto con el PIB como con el IPC se ha conseguido crear modelos con buenos resultados que se ven reflejados en las métricas de error, unos errores que se han minimizado tanto como se ha podido. Además, las predicciones realizadas son coherentes y se ajustan a las expectativas previstas. Asimismo, tal y como se pedía en uno de los objetivos del reto, estas estimaciones se han **comparado** con los **datos reales** y con otras **estimaciones hechas por autoridades oficiales**.

Los **datos reales** que se han utilizado para realizar la comparación han sido datos obtenidos del **ISTAT** (Instituto Nacional de Estadística Italiana). Sin embargo, en lo que respecta al PIB, los datos que presentaba dicha entidad eran diferentes a los datos de los que se disponía para hacer la predicción. Por lo tanto, se ha creído mejor hacer otra estimación con los datos del ISTAT para ver y analizar los resultados que daba este. La predicción obtenida con los datos del ISTAT ha sido parecida a la que se ha obtenido con los datos proporcionados, por lo que se entiende que, aunque los datos no sean del todo iguales, **el modelo empleado hace estimaciones acertadas**. Igualmente, se ha comparado el valor real con la predicción realizada originalmente. Esta predicción es de 495.179 millones de €, mientras que el valor real corresponde a 498.856 millones de €. En este caso, el error ha sido de 3.677 millones de €, cantidad no muy grande si se tiene en mente la magnitud de la escala en la que se sitúan estos datos.

En lo que se refiere al **IPC**, los datos del ISTAT sí que eran muy similares a los datos que se tenían, con lo que la comparación se ha podido hacer sin problemas. Las previsiones hechas por el modelo son de 114.8475 millones de € para octubre, 115.5304 millones de € para noviembre y 116.3154 millones de € para diciembre, mientras que los valores reales son de

118.100, 118.700 y 119 millones de € respectivamente. Consecuentemente, dado que los datos reales son superiores a las previsiones, se puede decir que **el modelo es algo pesimista**. Aún y todo, **la diferencia entre datos es de 4 puntos, lo que no es muy significativo**.

A la hora de comparar las **estimaciones hechas por otras autoridades** oficiales con nuestras estimaciones también se han empleado las realizadas por el ISTAT. El **valor previsto por el ISTAT** para el PIB en el último trimestre de 2022 fue **de 443.883 millones de €**. Esta estimación **no es muy acertada** ya que tiene una **diferencia de 54.973 millones con el valor real y 51.296 millones con la predicción hecha por el modelo** empleado. Esto podría explicarse por el hecho de que esa estimación se realizó en un momento en el que la pandemia del COVID-19 seguía siendo una preocupación significativa, y durante ese período, la producción experimentó una disminución considerable. Por tanto, es posible que hubiesen optado por ser más conservadores en la estimación, dada la incertidumbre y las dificultades que la pandemia estaba causando en ese momento.

PIB (millones de €)	Último trimestre de 2022
Valor real	498.856
Nuestra predicción	495.179
Predicción de ISTAT	443.883

Tabla 7: Comparativa entre valor real, nuestra predicción y la predicción de ISTAT para el PIB

En lo que respecta al **IPC** la únicas estimaciones que se han encontrado han sido porcentajes de variación y no valores absolutos. En consecuencia, para poder realizar la comparación se han tenido que buscar estos porcentajes para los valores reales, y en el caso de nuestras predicciones, calcularlos a mano. **Las estimaciones hechas por ISTAT** fueron **de 3,5% para octubre, 0,5% para noviembre y 0,3% para diciembre**. En cambio los porcentajes reales son 3,4%, 0,5% y 0,3% respectivamente. Se puede observar que las previsiones realizadas por ISTAT fueron **muy acertadas**. Esto se debe a que las estimaciones realizadas por ISTAT se efectúan en proximidad a la fecha en que se conoce el valor real, por lo que es muy probable que acierten. Los porcentajes calculados en base a nuestras predicciones son 2,5%, 1,1% y 1,2%. En esta ocasión, **las previsiones del modelo** difieren bastante de las estimaciones hechas por ISTAT y **no son tan acertadas como ocurre con el PIB**.

IPC (millones de € y %)	Octubre 2022	Noviembre 2022	Diciembre 2022
Valor real	118.100 (3,4%)	118.700 (0,5%)	119.000 (0,3%)
Nuestra predicción	114.488 (2,5%)	115.756 (1,1%)	117.129 (1,2%)
Predicción de ISTAT	3,5%	0,5%	0,3%

Tabla 8: Comparativa entre valor real, nuestra predicción y la predicción de ISTAT para el IPC

5. Transformar los negocios

Este apartado pretende **guiar y aconsejar** a los diferentes clientes interesados en expandirse en el mercado italiano, pero antes que nada, y con el objetivo de que se entiendan mejor dichas recomendaciones, es importante estar familiarizado con el contexto económico actual del país.

Italia presume de una **zona norte** muy **industrializada** y dominada **por empresas privadas**, la cual contrasta con un **sur agrícola** y subvencionado con **altas tasas de desempleo**. Además, cabe mencionar que la economía del país está impulsada en gran medida por **empresas familiares pequeñas y medianas**, y que cuenta con una **economía sumergida**, más común en sectores agrícolas, de construcción y de servicios, que tampoco pasa desapercibida.

Si se habla desde un punto de vista más global, Italia está considerada **entre las 10 economías más fuertes** del mundo en lo que al PIB respecta, aunque un porcentaje de deuda pública que ronda el 140% sobre dicho índice la hace también una de las más **endeudadas**. En cuanto al IPC, los **precios de la vivienda y relacionados** han sido, por mucho, los que más **han aumentado** en los últimos años, lo que perjudica a personas hipotecadas o en alquiler a la vez que beneficia a inversores, que ven crecer el valor de sus propiedades.

Con este contexto en mente, y basándose en el resultado del estudio realizado, se puede dar respuesta a las preguntas planteadas por Laboral Kutxa. Cuando se considera una **posible expansión** en el mercado italiano, las opciones son varias. No obstante, dada la subdelegación para la cual es el proyecto y su enfoque, la **inversión en el mercado financiero** se considera la más adecuada. Aún y todo, y a pesar del alto valor del PIB, no se puede obviar su tasa de endeudamiento, la cual genera un riesgo añadido a las empresas que deseen invertir en el territorio. En este sentido, cabe destacar también que las empresas que más beneficio generan son las que pertenecen al **sector privado**, y por lo tanto, la inversión en dichas empresas son las más recomendadas. Algunos ejemplos de entidades bien posicionadas y que generan un beneficio significativo para los inversores son Enel, Gucci, Generali Group y Poste Italiane.

En cuanto al **IPC**, la pandemia del COVID-19 ha dejado una huella profunda en la economía mundial y esto ha tenido como consecuencia que haya habido un repunte en la **inflación**, así como una subida en los tipos de interés. Desde la visión de un inversor, esta es una **época perfecta para invertir** y obtener beneficio, siempre teniendo presente que la tasa disminuirá y volverá a los valores previos a la pandemia y que es entonces cuando hay que tener cuidado y estar pendiente de ajustar las estrategias.

Una estrategia a tener en cuenta es la **diversificación de la cartera**, lo cual consiste en proveer de una variedad de activos financieros como bonos o acciones, entre otros, con el objetivo de reducir el riesgo y maximizar las ganancias a largo plazo. Por otro lado, otra buena opción es **invertir en inmobiliaria** pues, como ya se ha mencionado, los precios de la vivienda han aumentado considerablemente, lo que recompensa a los que inviertan en propiedad.

En términos de sectores, es bien sabido que Italia es famosa por su **moda y diseño**, con lo que invertir en empresas líderes y mundialmente conocidas como el ya mencionado Gucci puede ser muy beneficioso. Asimismo, el país está experimentando un crecimiento en el **sector**

tecnológico, y es por eso que invertir en empresas con potencial en áreas como la inteligencia artificial, el software, o incluso la biotecnología, es digno a considerar.

6. Implicaciones legales y éticas

“La información es la gasolina del siglo XXI, y la analítica de datos el motor de combustión” – dijo Peter Sondergaard, ex-director de investigación en International Data Group Netherlands; y es que, sin análisis ni interpretación, los datos por sí solos no aportan ningún valor. Es por eso que, en los últimos años, las entidades financieras, entre otros, han decidido darle uso a la inmensa cantidad de información que recopilan a diario con el objetivo de conseguir algún tipo de beneficio.

En este contexto, Laboral Kutxa ha propuesto realizar predicciones para determinar, por ejemplo, si merece la pena invertir o expandirse en diferentes países. No obstante, ni el análisis de datos es tan sencillo, ni su resultado tan inmediato, pues hay múltiples factores externos capaces de alterar cualquier previsión.

Por un lado, se debe tener en cuenta que **la solvencia de un país no solo se define por variables de carácter económico** como el PIB o el IPC, sino que también se ve afectada por el Índice de Desarrollo Humano (IDH), la esperanza de vida, y otros muchos índices que miden la calidad de vida del territorio. Por otro lado, es bien sabido que el **contexto socioeconómico** actual es muy **cambiante**, debido, en gran medida, a las todavía presentes consecuencias de la pandemia del COVID-19, así como a las consecuencias de los diferentes conflictos bélicos.

Consecuentemente, se podría decir que una limitación de este reto está causada por la **escasez de variables** proporcionadas para realizar las predicciones, ya que esto dificulta conseguir un modelo tan fiable como se querría. Si bien es cierto que el modelo creado devuelve unos resultados bastante realistas en lo que al 2022 respecta, el hecho de contar con datos de carácter social y cultural, y por qué no, con más variables económicas, aportaría un valor adicional al modelo y permitiría anticiparse más efectivamente a sucesos futuros capaces de alterar el ciclo económico.

En relación con lo anterior, es un hecho que **la inversión por parte de Laboral Kutxa tiene un impacto directo sobre sus clientes** con un producto financiero contratado. Por lo tanto, la entidad debe informar tanto sobre dichas decisiones como sobre su “seguridad” si es que quiere mantenerse firme a su propuesta de “una forma de hacer única, personal y [suya], que se basa en una relación con [sus] clientes, marcada por la transparencia y la confianza, y en un trato cercano y personalizado”. Asimismo, la narrativa sobre la situación y la propuesta deberá hacerse de manera clara, neutra y objetiva, tratando de influenciar lo mínimo posible en cómo pueda ser interpretada por el cliente.

Con este reto, hay múltiples Objetivos de Desarrollo Sostenible (ODS) en los que se podría afectar positivamente. En primer lugar y principalmente, en el **ODS número 8** (trabajo decente y crecimiento económico), pues como la entidad transmite, son una cooperativa que mantiene “abanicos salariales estrechos que aseguran un reparto justo y solidario de [sus] beneficios”. Relacionado con el anterior, el **ODS número 5** (igualdad de género), impulsado por una participación plena y efectiva de las mujeres en las categorías profesionales de la entidad. Un último ejemplo puede ser el **ODS número 11** (industria, innovación e infraestructuras), ya que, a través de una inversión y/o expansión, Laboral Kutxa no solo genera empleo, sino que también desempeña un papel clave en lo que respecta a la introducción y promoción de las nuevas tecnologías, a la facilitación del comercio internacional, y al uso eficiente de recursos.

En conclusión, a la hora de tomar una decisión tan importante como es crecer como empresa en otros países, las predicciones son una herramienta muy útil siempre y cuándo sean basadas en información de calidad y suficiente. Aún y todo, como bien se ha mencionado, predecir el futuro nunca es una ciencia exacta, por lo que no es recomendable tener fé ciega en lo que pueda decir un modelo. Esto es, **las predicciones son recursos donde apoyarse, pero siempre manteniendo el criterio propio y conociendo las novedades del panorama socioeconómico**, que pueden cambiar rápida y completamente todos los planes por muy preparado que se esté.

Bibliografía

- **Datos reales del PIB e IPC de Italia:**

Página web del Instituto Nacional de Estadística de Italia

<https://www.istat.it/>

Base de datos del Instituto Nacional de Estadística de Italia. *Producto interior bruto y sus componentes principales.*

https://esploradati.istat.it/databrowser/#/en/dw/categories/IT1,DATAWAREHOUSE,1.0/UP_ACC_TRIMES/IT1,163_184_DF_DCCN_PILQ_1,1.0

Base de datos del Instituto Nacional de Estadística de Italia. *Índice de precios de consumo para toda la nación.*

https://esploradati.istat.it/databrowser/#/en/dw/categories/IT1,Z0400PRI,1.0/PRI_CO_NWHONAT/DCSP_NIC1B2015/IT1,167_744_DF_DCSP_NIC1B2015_1,1.0

- **Datos estimados por ISTAT del PIB e IPC:**

Base de datos del Instituto Nacional de Estadística de Italia. *Producto interior bruto y tasa de crecimiento (estimaciones preliminares).*

https://esploradati.istat.it/databrowser/#/en/dw/categories/IT1,DATAWAREHOUSE,1.0/UP_ACC_TRIMES/IT1,163_156_DF_DCCN_SQCQ_3,1.0

Instituto Nacional de Estadística de Italia. (30 de septiembre de 2022). *Datos provisionales del IPC para septiembre de 2022.*

<https://www.istat.it/en/archivio/275238>

Instituto Nacional de Estadística de Italia. (28 de octubre de 2022). *Datos provisionales del IPC para octubre de 2022.*

<https://www.istat.it/en/archivio/276686>

Instituto Nacional de Estadística de Italia. (30 de noviembre de 2022). *Datos provisionales del IPC para noviembre de 2022.*

<https://www.istat.it/en/archivio/278337>

Instituto Nacional de Estadística de Italia. (05 de enero de 2023). *Datos provisionales del IPC para diciembre de 2022.*

<https://www.istat.it/en/archivio/279543>

- **Ética:**

BBVA. (28 de febrero de 2018). *7 citas para dar valor a los datos.*

<https://www.bbva.com/es/innovacion/7-citas-dar-valor-datos/>

Merca2.0. (10 de abril de 2018). *7 frases sobre Big Data que recuerdan al mercadólogo su relevancia.*

<https://www.merca20.com/frases-sobre-big-data-que-recuerdan-al-mercadologo-su-relevancia/>

Laboral Kutxa. *La entidad.*

<https://corporativa.laboralkutxa.com/nosotros/la-entidad/>

Laboral Kutxa. (20 de marzo de 2018). *En LABORAL Kutxa nos unimos a los Objetivos de Desarrollo Sostenible de las Naciones Unidas.*

<https://blog.laboralkutxa.com/es/objetivos-desarrollo-sostenible-naciones-unidas>

Apéndice I: Interpretaciones matemáticas

En este apéndice se presentan las interpretaciones matemáticas de los diferentes criterios de evaluación, algoritmos, métodos de validación, métricas y conceptos matemáticos y estadísticos empleados en el reto.

En cuanto a los criterios de evaluación se han empleado los criterios de evaluación AIC, AICc y BIC, para poder seleccionar el modelo más adecuado. El criterio **AIC** (criterio de información Akaike) se basa en la entropía de la información y su objetivo es encontrar un equilibrio entre la bondad de ajuste del modelo y su complejidad para evitar el sobreajuste y seleccionar así el modelo que mejor se ajuste a los datos, representa una estimación sobre la información perdida por el modelo. El cálculo de este criterio de evaluación se realiza con la siguiente fórmula: $AIC = 2k - 2\ln(L)$, siendo la k el número de parámetros y la L el máximo valor de la función de verosimilitud para el modelo estimado. Se penalizan de forma creciente según el número de parámetros del modelo, es decir, se busca el modelo que tenga un buen ajuste a los datos con la menor cantidad de parámetros. El mejor modelo será el que tenga menor valor de AIC.

También, se ha empleado el criterio de evaluación **AICc** (Criterio de Información de Akaike corregido), AICc es una extensión y mejora del ya conocido AIC con una corrección para muestras pequeñas, esta corrección es especialmente importante porque puede prevenir la selección de modelos sobre ajustados. La fórmula de este modelo es la siguiente :

$AICc = AIC + \frac{2k^2 + 2k}{n - k - 1}$, siendo n el tamaño de la muestra. Como en el anterior caso el mejor modelo será el que muestre el valor más bajo.

Por otro lado, se ha utilizado el criterio **BIC** (criterio de información bayesiano), el objetivo en este caso es maximizar la probabilidad del modelo a largo plazo dada la serie. Este criterio cuenta con la siguiente fórmula: $BIC = k \ln(n) - 2\ln(L)$, a la hora de seleccionar el modelo se elige el modelo que tenga el valor de BIC más bajo, ya que esto indica una mayor probabilidad a largo plazo del modelo dado el conjunto de datos.

Tras evaluar los datos se ha de crear un modelo, para ello hemos decidido emplear el algoritmo **ARIMA** (AutoRegressive Integrated Moving Average). Este es un modelo mixto compuesto por una parte autorregresiva de orden p , otra parte de media móvil de orden q y las diferencias de la serie de orden d . Se utiliza para predecir valores futuros basándose en patrones y tendencias pasadas teniendo en cuenta que su aplicación se hace en series no estacionarias.

Para evaluar el rendimiento de nuestro modelo, se ha aplicado la **validación cruzada** de series temporales, el funcionamiento de esta validación es el siguiente; al dividir los datos, se dividen en conjuntos manteniendo las relaciones temporales naturales de los datos. Esto significa que los datos anteriores en el tiempo se utilizan para entrenar y los demás para evaluar, teniendo en cuenta la dependencia temporal de los datos.

Para poder evaluar los algoritmos y saber cómo de buenas son nuestras predicciones se utilizan diferentes métricas, empezando por **Error**, es el error es la diferencia entre un valor observado o medido y un valor teórico o esperado. Siguiendo por el **Error Cuadrado** se calcula elevando al cuadrado las diferencias individuales entre los valores observados y los valores

esperados. Luego también está el **Error Absoluto** se calcula tomando el valor absoluto de las diferencias individuales entre los valores observados y los valores esperados. Después, está la **Raíz Cuadrada del Error Cuadrado Medio (RMSE)**, que es una medida que proporciona una idea de la magnitud promedio de los errores en un conjunto de datos. Además, tenemos **Error Cuadrado Medio (MSE)**, que se calcula sumando todos los errores cuadrados y dividiendo por el número de observaciones. Para finalizar también podemos ver **Error Absoluto Medio (MAE)** que se calcula sumando todos los errores absolutos y dividiendo por el número de observaciones.

Apéndice II: InfluxDB

InfluxDB es una base de datos de series temporales con alta disponibilidad capaz de un almacenamiento rápido y supervisado de los mismos.

Para este reto, se ha pedido la **creación de dichas BBDD** con los datos proporcionados, además de la **captura de una serie de consultas** entre diferentes rangos de tiempo. En este contexto, el equipo Verde Oscuro ha llevado a cabo el proceso de manera rigurosa y detallada siguiendo los pasos que se explican a continuación.

En primer lugar, dado que los ficheros tienen que ser de tipo “.csv” para poder cargarlos, se prioriza la **conversión** de “exógenas_paises_punto2.xlsx”, pues “pib_ipc_paises_punto2.csv” ya estaba con el formato correcto. Con ambos archivos ya preparados, se importaron a *RStudio* a través de la función *read.csv()* con la intención de hacer un **breve preprocesamiento** de los mismos y poder así prevenir posibles errores o sesgos que se pudieran dar más adelante. Entre otras cosas, se comprobó que los datos estuvieran bien estructurados con la función *str()* y que no hubieran duplicidades con *table(duplicated())*; finalmente, solo hubo que ajustar la columna de la fecha, lo que se hizo con la ayuda de las funciones *strptime()* y *as.POSIXct()*. Además, se decidió **separar la tabla del IPC y el PIB** en dos con el objetivo de facilitar el trabajo posterior.

A continuación, se comenzaron a crear los tres **buckets**, empleando el mismo código para todos ellos. Para ello, la función utilizada es *POST()*, de la librería “httr”, donde se debe indicar cierta información como el “url” de InfluxDB, el nombre que se le quiera poner al bucket, el ID de la organización y el token personal.

Por último, solo queda **escribir la información** de cada tabla en su bucket correspondiente. Antes que nada, esto **requiere de una conexión (API)** a través de *InfluxDBClient\$new()*, de la librería “influxdbclient”, proporcionando tanto el “url” como el token y la organización. Así, ya es posible copiar los datos en las BBDD de series temporales con *client\$new()*, siendo “client” cómo se ha definido la conexión hecha anteriormente. Cabe mencionar que a la hora de escribir la información en InfluxDB se deben definir el “measurement”, las columnas “tag”, la columna de tiempo, etc.

Una vez creados los buckets, se procedió con la captura de **tres consultas**, una para cada caso. Por un lado, la primera de ellas filtra los datos de Italia del bucket de variables exógenas y devuelve la que fue la tasa de paro del país a lo largo del año 2000. Por otro lado, la segunda consulta, correspondiente al bucket del IPC, filtra de nuevo los datos de Italia pero, en este caso, calcula la media anual de dicho índice desde 1996 hasta 2001. En cuanto a la tercera y última consulta, se tienen en cuenta los datos de todos los países europeos, los cuales se ordenan de manera descendente según su valor promedio de PIB en el año 2000.

Las consultas se ejecutan con la ayuda de la función *client\$query()*, es decir, empleando otra vez la conexión API que se hizo en el paso anterior. Devuelven la siguiente información, respectivamente:

Oracle VM VirtualBox

28 de oct 18:41

RStudio

R5_repositorio_verdeoscuro - main - RStudio

```
12 # Consulta 1: Tasa de paro en Italia durante el año 2000 ----
13
14 consulta1 <- 'from(bucket: "bucket_R05_verdeoscuro_exp")
15 |> range(start: 2000-01-01T00:00:00Z, stop: 2001-01-01T00:00:00Z)
16 |> filter(fn: (r) => r["country"] == "Italy")
17 |> filter(fn: (r) => r["code"] == "ITA")
18 |> filter(fn: (r) => r["contentCode"] == "EU")
19 |> filter(fn: (r) => r["_field"] == "Unemployment.rate.percent")'
20
21 consulta1 <- gsub("[\\r\\n]", "", consulta1) # ignoramos los saltos de línea
22
23 data1 <- client.query(consulta1)
24
```

Console

```
R 4.3.1 - ~/Documents/23-24_2_R5_VERDE_OSCURO/R5_repositorio_verdeoscuro > data1
[[1]]
      _start_      _stop_      _time_ _value_ ContinentCode Country      _field_ _measurement_      time
1 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-01-01T00:00:00+00:00 10.2 ITA EU Italy Unemployment.rate.percent Italy 2000-01-01 00:00:00
2 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-02-01T00:00:00+00:00 11.1 ITA EU Italy Unemployment.rate.percent Italy 2000-02-01 00:00:00
3 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-03-01T00:00:00+00:00 11.1 ITA EU Italy Unemployment.rate.percent Italy 2000-03-01 00:00:00
4 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-04-01T00:00:00+00:00 11.2 ITA EU Italy Unemployment.rate.percent Italy 2000-04-01 00:00:00
5 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-05-01T00:00:00+00:00 11.2 ITA EU Italy Unemployment.rate.percent Italy 2000-05-01 00:00:00
6 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-06-01T00:00:00+00:00 10.7 ITA EU Italy Unemployment.rate.percent Italy 2000-06-01 00:00:00
7 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-07-01T00:00:00+00:00 10.7 ITA EU Italy Unemployment.rate.percent Italy 2000-07-01 00:00:00
8 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-08-01T00:00:00+00:00 10.8 ITA EU Italy Unemployment.rate.percent Italy 2000-08-01 00:00:00
9 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-09-01T00:00:00+00:00 10.8 ITA EU Italy Unemployment.rate.percent Italy 2000-09-01 00:00:00
10 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-10-01T00:00:00+00:00 10.2 ITA EU Italy Unemployment.rate.percent Italy 2000-10-01 00:00:00
11 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-11-01T00:00:00+00:00 10.2 ITA EU Italy Unemployment.rate.percent Italy 2000-11-01 00:00:00
12 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-12-01T00:00:00+00:00 10.5 ITA EU Italy Unemployment.rate.percent Italy 2000-12-01 00:00:00
13 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-01-01T00:00:00+00:00 10.5 ITA EU Italy Unemployment.rate.percent Italy 2001-01-01 00:00:00
14 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-02-01T00:00:00+00:00 9.5 ITA EU Italy Unemployment.rate.percent Italy 2000-02-01 00:00:00
15 2000-01-01T00:00:00 2001-01-01T00:00:00 2000-03-01T00:00:00+00:00 9.5 ITA EU Italy Unemployment.rate.percent Italy 2000-03-01 00:00:00
```

Environment

Global Environment

Data

data1 List of 1

Values

client <Object conta...

consu... "from(bucket:..."

Files Plots Packa...

R: POST file to a server.

POST (html) Documentation

POST file to a server.

Description

Usage

POST

url = NULL,

config = list(),

Oracle VM VirtualBox

28 de oct 18:43

RStudio

R5_repositorio_verdeoscuro - main - RStudio

```
25 # Consulta 2: IPC medio de Italia por año desde 1996 a 2001 ----
26
27 consulta2 <- 'import "contrib/bonito-to/tickscrip"
28 from(bucket: "bucket_R05_verdeoscuro_ipc")
29 |> range(start: 1996-01-01T00:00:00Z, stop: 2001-01-01T00:00:00Z)
30 |> filter(fn: (r) => r["country"] == "Italy")
31 |> filter(fn: (r) => r["code"] == "ITA")
32 |> filter(fn: (r) => r["contentCode"] == "EU")
33 |> filter(fn: (r) => r["_field"] == "Consumer.Price.Index..CPI.")
34 |> aggregateWindow(every: 1y, fn: mean)
35 |> yield(name: "mean")'
36
37 consulta2 <- gsub("[\\r\\n]", "", consulta2) # ignoramos los saltos de línea
38
39 data2 <- client.query(consulta2)
40
```

Console

```
R 4.3.1 - ~/Documents/23-24_2_R5_VERDE_OSCURO/R5_repositorio_verdeoscuro > data2
[[1]]
      _start_      _stop_      _time_ _value_ ContinentCode Country      _field_ _measurement_      time
1 1996-01-01T00:00:00 2001-01-01T00:00:00 1997-01-01T00:00:00+00:00 68.53478 ITA EU Italy Consumer.Price.Index..CPI Italy 1997-01-01 00:00:00
2 1996-01-01T00:00:00 2001-01-01T00:00:00 1998-01-01T00:00:00+00:00 68.53478 ITA EU Italy Consumer.Price.Index..CPI Italy 1998-01-01 00:00:00
3 1996-01-01T00:00:00 2001-01-01T00:00:00 1999-01-01T00:00:00+00:00 71.15833 ITA EU Italy Consumer.Price.Index..CPI Italy 1999-01-01 00:00:00
4 1996-01-01T00:00:00 2001-01-01T00:00:00 2000-01-01T00:00:00+00:00 72.32560 ITA EU Italy Consumer.Price.Index..CPI Italy 2000-01-01 00:00:00
5 1996-01-01T00:00:00 2001-01-01T00:00:00 2001-01-01T00:00:00+00:00 74.21667 ITA EU Italy Consumer.Price.Index..CPI Italy 2001-01-01 00:00:00
6 1996-01-01T00:00:00 2001-01-01T00:00:00 2001-01-01T00:00:00+00:00 75.00000 ITA EU Italy Consumer.Price.Index..CPI Italy 2001-01-01 00:00:00
```

Environment

Global Environment

Data

data2 List of 1

Values

client <Object conta...

consu... "from(bucket:..."

Files Plots Packa...

R: POST file to a server.

POST (html) Documentation

POST file to a server.

Description

Usage

POST

url = NULL,

config = list(),

Oracle VM VirtualBox

28 de oct 18:45

RStudio

R5_repositorio_verdeoscuro - main - RStudio

```
43 consulta3 <- 'from(bucket: "bucket_R05_verdeoscuro_pi3")
44 |> range(start: 2000-01-01T00:00:00Z, stop: 2001-01-01T00:00:00Z)
45 |> filter(fn: (r) => r["_measurement"] == "France" or r["_measurement"] == "Italy" or r["_measurement"] == "Norway" or r["_measurement"] == "United Kingdom")
46 |> filter(fn: (r) => r["code"] == "DEU" or r["code"] == "FRA" or r["code"] == "GBR" or r["code"] == "ITA" or r["code"] == "NOR")
47 |> filter(fn: (r) => r["contentCode"] == "EU")
48 |> filter(fn: (r) => r["country"] == "France" or r["country"] == "Italy" or r["country"] == "United Kingdom" or r["country"] == "Norway" or r["country"] == "Germany")
49 |> filter(fn: (r) => r["_field"] == "GDP.billion.currency.units")
50 |> aggregateWindow(every: 1y, fn: mean, createEmpty: false)
51 |> groupColumns: ["contentCode"]
52 |> yield(name: "mean")
53 |> sort(columns: ["_value"], desc: false)
54 |> keep(columns: ["mean"])'
55
56 consulta3 <- gsub("[\\r\\n]", "", consulta3) # ignoramos los saltos de línea
57
58 data3 <- client.query(consulta3)
59
```

Console

```
R 4.3.1 - ~/Documents/23-24_2_R5_VERDE_OSCURO/R5_repositorio_verdeoscuro > data3
[[1]]
      _start_      _stop_      _time_ _value_ Code ContinentCode Country      _field_ _measurement_      time
1 2000-01-01T00:00:00 2001-01-01T00:00:00 2001-01-01T00:00:00+00:00 369.6475 FRA EU France GDP.billion.currency.units France 2001-01-01
2 2000-01-01T00:00:00 2001-01-01T00:00:00 2001-01-01T00:00:00+00:00 527.2725 DEU EU Germany GDP.billion.currency.units Germany 2001-01-01
3 2000-01-01T00:00:00 2001-01-01T00:00:00 2001-01-01T00:00:00+00:00 310.3800 ITA EU Italy GDP.billion.currency.units Italy 2001-01-01
4 2000-01-01T00:00:00 2001-01-01T00:00:00 2001-01-01T00:00:00+00:00 46.4625 NOR EU Norway GDP.billion.currency.units Norway 2001-01-01
5 2000-01-01T00:00:00 2001-01-01T00:00:00 2001-01-01T00:00:00+00:00 274.6250 GBR EU United Kingdom GDP.billion.currency.units United Kingdom 2001-01-01
```

Environment

Global Environment

Data

data1 List of 1

data2 List of 1

data3 List of 2

Values

client <Object conta...

consu... "from(bucket:..."

Files Plots Packa...

R: POST file to a server.

POST (html) Documentation

POST file to a server.

Description

Usage

POST

url = NULL,

config = list(),

Glosario de terminología

Variable exógena: variable que afecta al resultado pero es externa al modelo.

Histograma: diagrama estadístico en el que se representa un conjunto de datos estadísticos mediante barras rectangulares, de manera que cada barra del histograma es proporcional a su frecuencia correspondiente.

Serie temporal: conjunto de datos u observaciones que hace referencia a una o varias variables y que está ordenado cronológicamente.

Tendencia: propensión o inclinación de un periodo temporal.

Estacionalidad: repetición de determinadas variaciones en alguna variable cada cierto período.

Momento cíclico: circunstancia que altera el ciclo de la economía.

Autocorrelación: grado de similitud entre los valores de las mismas variables en intervalos de tiempo sucesivos.

Autocorrelación parcial: relación entre una observación en una serie de tiempo y datos de pasos de tiempo anteriores que no toman en cuenta las correlaciones entre las observaciones intermedias.

Minería de datos: proceso de descubrir patrones y otra información valiosa de grandes conjuntos de datos.

Ruido blanco: proceso estocástico que se caracteriza por el hecho de que sus valores de señal en dos tiempos diferentes no guardan correlación estadística.

Validación cruzada: método de remuestreo estadístico que se utiliza para evaluar el rendimiento del modelo de aprendizaje automático.

Glosario de siglas

PIB: Producto Interior Bruto

IPC: Índice de Precios de Consumo

AIC: Akaike Information Criterion (Criterio de Información de Akaike)

AICc: Corrected Akaike Information Criterion (Criterio de Información de Akaike corregido)

BIC: Bayesian Information Criterion (Criterio de Información Bayesian)

API: Application Programming Interfaces (Interfaz de Programación de Aplicaciones)

RMSE: Root-Mean-Square Error (Raíz del Error Cuadrático Medio)

MSE: Mean Squared Error (Error Cuadrático Medio)

MAE: Mean Absolute Error (Error Absoluto Medio)

ME: Mean Error (Error Medio)

ARIMA: Auto-Regressive Integrated Moving Average (Modelo Autorregresivo Integrado de Media Móvil)

ODS: Objetivos de Desarrollo Sostenible